PTO ISA Compiler

Programmable Tensor Operations (PTO) 是一种面向张量计算的领域特定语言（DSL），提供统一的编程模型来描述深度学习算子，并支持编译到多种硬件后端。

目录

---

1. PTO ISA 定义

1.1 指令集概述

PTO ISA 定义了一套平台无关的张量操作指令集，包括：

类别	指令	描述
数据移动	`TLOAD`, `TSTORE`	Tile 加载/存储
算术运算	`TADD`, `TSUB`, `TMUL`, `TDIV`	逐元素算术
矩阵运算	`TMATMUL`, `TMATMUL_ACC`	矩阵乘法
归约运算	`TROWSUM`, `TROWMAX`, `TCOLSUM`	行/列归约
激活函数	`TEXP`, `TLOG`, `TSQRT`, `TSILU`	非线性变换
广播运算	`TROWEXPANDSUB`, `TROWEXPANDDIV`	行广播
标量运算	`SADD`, `SMUL`, `SLI`, `SCMP`	标量计算
控制流	`FOR`, `IF`, `CALL`, `RETURN`	程序控制

1.2 多后端代码生成

PTO 编译器支持将统一的 PTO ISA 编译到多种物理 ISA：

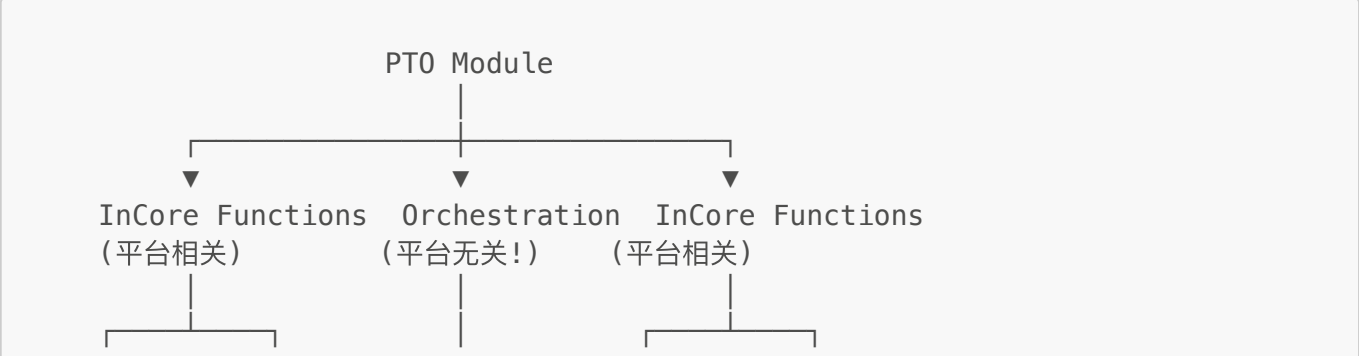

```
   ▼         ▼          ▼          ▼          ▼
ARM64     CUDA       纯 C 代码    Ascend     ...
NEON      Kernels    (调用 PTO    910B
(.c)      (.cu)      Runtime)     (.cpp)
                     (.c)
```

关键设计原则：

- **InCore Functions**: 平台相关，编译到 ARM64/CUDA/Ascend 物理 ISA
- **Orchestration Functions**: **平台无关**，只调用 PTO Runtime 的 task 接口
- 同一份 Orchestration 代码用于所有后端

代码生成示例：

```
PTO ISA:          TADD %c, %a, %b
                        │
    ┌───────────────────┼──────────────────┐
    ▼                   ▼                  ▼
ARM64 NEON:       CUDA:              Ascend 910B:
vaddq_f32(a,b)    c[i] = a[i]+b[i]   Add(c, a, b, n)
```

1.3 编译优化

- **Loop Fusion**: 合并相邻循环，减少循环开销
- **Buffer Reuse**: 基于 Tile 生命周期分析复用缓冲区
- **Inline Expansion**: InCore 函数调用内联展开

---

2. 编程接口 - Function Builder

2.1 概述

`PTOFunctionBuilder` 提供 Fluent API 来构建 PTO 程序：

```python
from pto_compile import PTOFunctionBuilder, PTOModule

# 创建模块
module = PTOModule("my_module")

# 构建函数
builder = PTOFunctionBuilder("my_function", module=module)
program = (builder
    .in_core()                                    # 声明为 InCore 函数
    .memref("input", MemorySpace.GLOBAL, ElementType.F32)
    .memref("output", MemorySpace.GLOBAL, ElementType.F32)
    .tile("x", 8, 8, ElementType.F32)
    .load("x", "input")                           # TLOAD
    .exp("y", "x")                                # TEXP
```

```
    .store("output", "y")                          # TSTORE
    .build())
```

2.2 函数类型：InCore vs Orchestration

PTO 定义了两种函数类型，具有不同的语义和执行模式：

特性	InCore Function	Orchestration Function
声明方式	`.in_core()`	`.not_in_core()`
执行位置	计算核心 (GPU/NPU/CPU SIMD)	主机 CPU
物理 ISA	CUDA / Ascend C / ARM64 NEON	ARM64 C
主要内容	Tile 级张量操作	控制流 + CALL InCore 函数
嵌套调用	被内联展开	保留 CALL，生成任务调度代码
内存模型	核内 Tile Buffer	全局内存指针

InCore Function 示例

```
def create_rowmax():
    """InCore: 计算行最大值，在计算核心执行"""
    return (PTOFunctionBuilder("rowmax", module=module)
        .in_core()                                 # ← InCore 函数
        .memref("input", MemorySpace.GLOBAL, ElementType.F32)
        .memref("output", MemorySpace.GLOBAL, ElementType.F32)
        .tile("x", 8, 8, ElementType.F32)
        .tile("result", 8, 1, ElementType.F32)     # 归约输出
        .load("x", "input")
        .rowmax("result", "x")                     # TROWMAX 指令
        .store("output", "result")
        .build())
```

生成的 CUDA 代码：

```
__global__ void rowmax(float* input, float* output) {
    float x[8][8], result[8][1];
    // TLOAD
    for (int _row = 0; _row < 8; _row++)
        for (int _col = 0; _col < 8; _col++)
            x[_row][_col] = input[_row * 8 + _col];
    // TROWMAX
    for (int _row = 0; _row < 8; _row++) {
        float _max = x[_row][0];
        for (int _col = 1; _col < 8; _col++)
            if (x[_row][_col] > _max) _max = x[_row][_col];
        result[_row][0] = _max;
```

```
    }
    // TSTORE
    ...
}
```

Orchestration Function 示例

```python
def create_dynamic_softmax():
    """Orchestration: 动态分块，在主机 CPU 执行"""
    return (PTOFunctionBuilder("dynamic_softmax", module=module)
        .not_in_core()                              # ← Orchestration 函数
        .memref("input", MemorySpace.GLOBAL, ElementType.F32)
        .memref("output", MemorySpace.GLOBAL, ElementType.F32)
        .scalar("num_tiles", ElementType.I32)      # 动态参数

        # 动态循环 - 根据输入大小迭代
        .for_loop("tile_idx", 0, "num_tiles", 1)
            # CALL InCore 函数 - 使用偏移参数区分不同 tile
            # 格式: ("tensor_name", "loop_var", col_offset)
            .call("rowmax", {
                "input": ("input", "tile_idx", 0),      # input[tile_idx]
                "output": ("temp_max", "tile_idx", 0)
            })
            .call("rowexpandsub", {
                "input_x": ("input", "tile_idx", 0),
                "input_row": ("temp_max", "tile_idx", 0),
                "output": ("temp_shifted", "tile_idx", 0)
            })
            # ... 其他 CALL
        .end_for()
    .build())
```

生成的 ARM64 C 代码（主机端）：

```
void dynamic_softmax(PTORuntime* rt, float* input, float* output,
                     int num_tiles) {
    for (int tile_idx = 0; tile_idx < num_tiles; tile_idx++) {
        // CALL 指令转换为任务调度代码
        int32_t t0 = pto_task_alloc(rt, "rowmax", NULL, 288, 288);
        pto_task_add_input(rt, t0, input, tile_idx, 0, 8, 8);
        pto_task_add_output(rt, t0, temp_max, tile_idx, 0, 8, 1);
        pto_task_submit(rt, t0);

        int32_t t1 = pto_task_alloc(rt, "rowexpandsub", ...);
        // ... 依赖自动建立
    }
}
```

2.3 CALL 指令与偏移参数

在 Orchestration 函数中，`.call()` 支持两种参数格式：

```
# 格式 1: 简单参数（无偏移）
.call("func_name", {"param": "tensor_name"})

# 格式 2: 带偏移参数（用于动态 tiling）
.call("func_name", {"param": ("tensor_name", "row_offset", col_offset)})
```

偏移参数说明：

- `tensor_name`: 全局内存中的张量名
- `row_offset`: 行偏移表达式，可以是：
  - 循环变量名（如 `"tile_i"`, `"q_tile"`）
  - 标量变量名
  - 整数常量（如 `0`）
- `col_offset`: 列偏移，通常为 `0`

示例：LLaMA Flash Attention 的三阶段依赖

```
# Phase 1: Pre-Attention（所有 tile 并行）
.for_loop("tile_i", 0, "num_tiles", 1)
    .call("rmsnorm_tile", {
        "input": ("input", "tile_i", 0),        # input[tile_i]
        "output": ("temp_norm", "tile_i", 0)
    })
    .call("tile_matmul", {
        "input_a": ("temp_norm", "tile_i", 0),
        "input_b": "wq",                        # 共享权重，无偏移
        "output": ("all_q_tiles", "tile_i", 0)
    })
.end_for()

# Phase 2: Flash Attention（交叉 tile 依赖）
.for_loop("q_tile", 0, "num_tiles", 1)
    .for_loop("kv_tile", 0, "num_tiles", 1)
        .call("flash_attn_score_block", {
            "input_q": ("all_q_rope", "q_tile", 0),   # Q[q_tile]
            "input_k": ("all_k_rope", "kv_tile", 0),  # K[kv_tile] ← 交叉依
赖!
            "output_s": ("temp_scores", "q_tile", 0)
        })
    .end_for()
.end_for()
```

偏移的作用：

- 不同 tile 使用不同偏移，使得任务之间**没有虚假依赖**

- Runtime 可以正确识别并行机会
- Phase 1 和 Phase 3: 所有 tile 完全并行
- Phase 2: Q[i] 依赖所有 K[j], V[j]，形成 N×N 交叉依赖

2.4 编程语法对比

操作	InCore Function	Orchestration Function
Tile 操作	`.add()`, `.mul()`, `.exp()`	❌ 不支持
标量运算	`.scalar_add()`	`.scalar_add()`
控制流	`.for_loop()`, `.if_then()`	`.for_loop()`, `.if_then()`
函数调用	`.call()` → 内联展开	`.call()` → 生成任务调度代码
偏移参数	❌ 不需要	✅ 支持 `("tensor", "offset", 0)`
内存访问	`.load()`, `.store()`	❌ 不支持

3. 文件接口 - .pto Assembly

3.1 格式说明

`.pto` 文件是 PTO 程序的文本表示形式，与 Function Builder 构建的程序等价：

```
// 模块声明
// PTO Module: softmax_module
// Entry: @dynamic_softmax

// InCore 函数定义
// Function Type: InCore
func @rowmax(%input: !pto.memref<gm,...,f32>, %output:
!pto.memref<gm,...,f32>) {
  // Tile 声明
  %x = alloc_tile : !pto.tile<8x8xf32>
  %result = alloc_tile : !pto.tile<8x1xf32>

  // 指令
  %x = tload %input[0, 0] : (!pto.memref) -> !pto.tile<8x8xf32>
  %result = trowmax %x : !pto.tile<8x8xf32> -> !pto.tile<8x1xf32>
  tstore %result, %output[0, 0]

  return
}

// Orchestration 函数定义
// Function Type: Orchestration
func @dynamic_softmax(%input: !pto.memref, %output: !pto.memref) {
  // 标量声明
  %num_tiles = alloc_scalar : i32
```

```
  // 动态循环
  FOR %tile_idx:idx, 0:idx, %num_tiles:idx, 1:idx
    CALL @rowmax(%input -> %input, %output -> %temp_max)
    CALL @rowexpandsub(...)
  ENDFOR

  return
}
```

3.2 双向转换

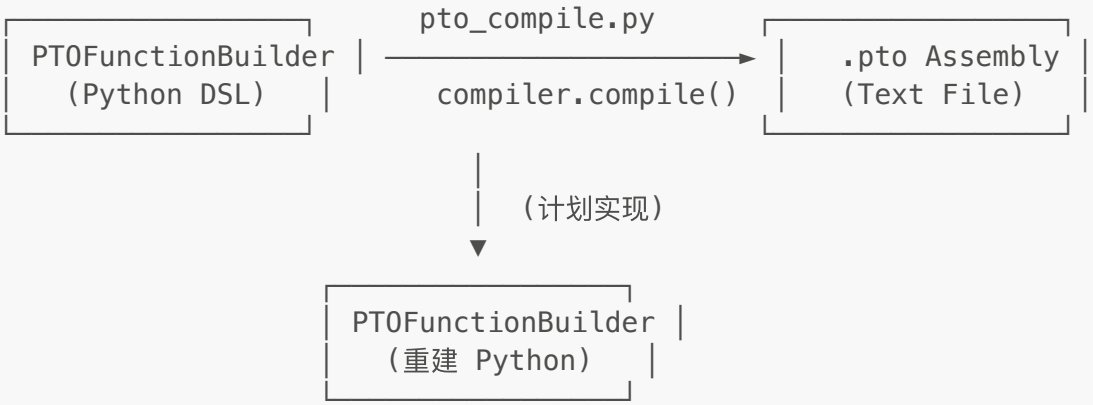

当前实现： Function Builder → .pto Assembly ✅
计划实现： .pto Assembly → Function Builder (用于编辑器支持、程序变换等)

---

4. Runtime Task 数据结构

4.1 概述

当执行 Orchestration Function 时，编译器生成的代码会构建 **Task Graph** 数据结构：

```
// 任务定义
typedef struct {
    char         func_name[64];       // InCore 函数名
    void*        func_ptr;            // 函数指针
    int32_t      fanin;               // 依赖计数
    int32_t      fanout_count;        // 下游任务数
    int32_t      fanout[512];         // 下游任务 ID
    TaskArg      args[16];            // 输入/输出参数
    int32_t      buffer_size;         // InCore 缓冲区大小
} PendingTask;

// 运行时状态
typedef struct {
    PendingTask  pend_task[65536];    // 待执行任务表
    TensorMap    tensor_map;          // 张量 → 生产者任务映射
    int32_t      ready_queue[1024];   // 就绪队列
```

```
    int64_t      total_tasks;         // 总任务数
} PTORuntime;
```

4.2 Task Graph 构建流程

```
Orchestration Function 执行
         |
         ▼
┌─────────────────────────────────────────────────────────────┐
|  for (tile_idx = 0; tile_idx < num_tiles; tile_idx++) {     |
|      // 每个 CALL 指令转换为:                                 |
|      task_id = pto_task_alloc(rt, "rowmax");                |
|      pto_task_add_input(rt, task_id, input, offset);        |
|      pto_task_add_output(rt, task_id, output, offset);      |
|      pto_task_submit(rt, task_id);  // 建立依赖              |
|  }                                                          |
└─────────────────────────────────────────────────────────────┘
         |
         ▼
   Task Graph 完成
   (pend_task[], fanin/fanout, ready_queue)
```

4.3 动态参数与 Task Graph 重建

关键特性： 每次使用不同的动态参数调用 Orchestration Function，都会重新执行并生成新的 Task Graph：

```
// 示例：不同 sequence length 生成不同 Task Graph
void run_llama_layer(int seq_len) {
    PTORuntime* rt = malloc(sizeof(PTORuntime));
    pto_runtime_init(rt);

    int num_tiles = seq_len / TILE_ROWS;

    // Orchestration function 是纯 C 代码，直接在主机 CPU 执行
    // 每次调用都重新构建 Task Graph
    llama_layer_dynamic(rt, input, output, num_tiles);

    // 此时 rt 包含完整的 Task Graph
    // 运行时可以：
    //   1. 并行调度 ready_queue 中的任务
    //   2. 完成任务后更新 fanin，解除依赖
    //   3. 新就绪的任务加入 ready_queue

    pto_runtime_shutdown(rt);
    free(rt);
}
```

4.4 LLaMA 7B 性能统计

以下是 LLaMA 7B Layer（含 Flash Attention）的 Task Graph 构建性能：

Sequence Length	Tiles	Tasks	Build Time	Tasks/ms	Memory	Per-Task
1K	32	3,584	0.855 ms	4,192	9.81 MB	2,872 B
2K	64	13,312	2.518 ms	5,287	36.41 MB	2,868 B
3K	96	29,184	6.036 ms	4,835	79.79 MB	2,867 B
4K	128	51,200	9.184 ms	5,575	139.95 MB	2,866 B

Task 数量公式： `Tasks = 16N + 3N²` (N = seq_len / tile_rows)

- Phase 1 (Pre-Attention): 6N tasks (并行)
- Phase 2 (Flash Attention): N(2 + 3N) tasks (交叉依赖)
- Phase 3 (Post-Attention/FFN): 8N tasks (并行)

数据结构大小：

- `sizeof(PendingTask)` = 2,864 bytes
- `sizeof(TensorMapEntry)` = 56 bytes
- 每任务平均内存 ≈ 2,870 bytes
- `PTO_MAX_TASKS` = 65,536 (可容纳 seq_len ≤ 4K)

---

5. Task Dump 与可视化

5.1 Dump 函数

```
// 输出到文件
pto_runtime_dump(rt, "task_graph.txt");

// 输出到 stdout
pto_runtime_dump_stdout(rt);
```

输出格式：

```
================================================================================
======
PTO RUNTIME DUMP
================================================================================
======

SUMMARY
  Total tasks scheduled:  40
  Ready queue size:       16

TASK TABLE
  Task 0: rowmax          [READY] fanin=0 buf=288.0KB fanout=[]
```

```
  Task 1: rowexpandsub   [READY] fanin=0 buf=544.0KB fanout=[2]
  Task 2: elem_exp       [WAIT]  fanin=1 buf=512.0KB fanout=[3,4]
  Task 3: rowsum         [WAIT]  fanin=1 buf=288.0KB fanout=[]
  Task 4: rowexpanddiv   [WAIT]  fanin=1 buf=544.0KB fanout=[]
  ...

DEPENDENCY GRAPH
  Task 1 -> Task 2
  Task 2 -> Task 3
  Task 2 -> Task 4
  ...
```

5.2 可视化工具

使用 `visualize_taskgraph.py` 将 Task Dump 转换为 PDF：

```
# 使用方式
python visualize_taskgraph.py <dump_file> <output_pdf>

# 示例
python visualize_taskgraph.py \
    examples/output_arm64/llama7b/llama_layer_dynamic_task_graph.txt \
    examples/output_arm64/llama7b/llama_layer_dynamic_task_graph.pdf
```

可视化特性：

- 左到右布局 (rankdir=LR)
- 同一执行层级的任务在同一列 (rank=same)
- 显示函数名和缓冲区大小
- 箭头表示依赖关系

示例输出：

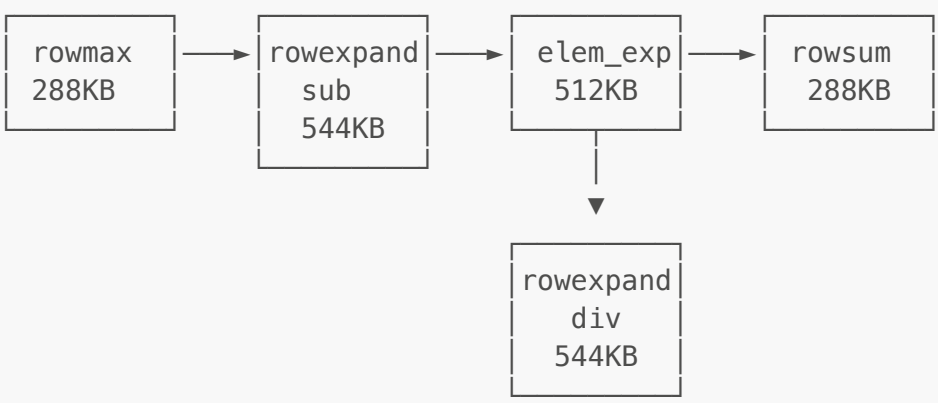

---

6. 动态 Shape 支持

6.1 问题背景

深度学习推理中，输入尺寸（如 sequence length）通常是动态的。传统静态编译方法需要为每种输入尺寸编译不同的 kernel，导致：

- 编译时间长
- 二进制体积大
- 无法处理未见过的尺寸

6.2 PTO 解决方案

PTO 通过 **Orchestration Function** 完全解决动态 shape 问题：

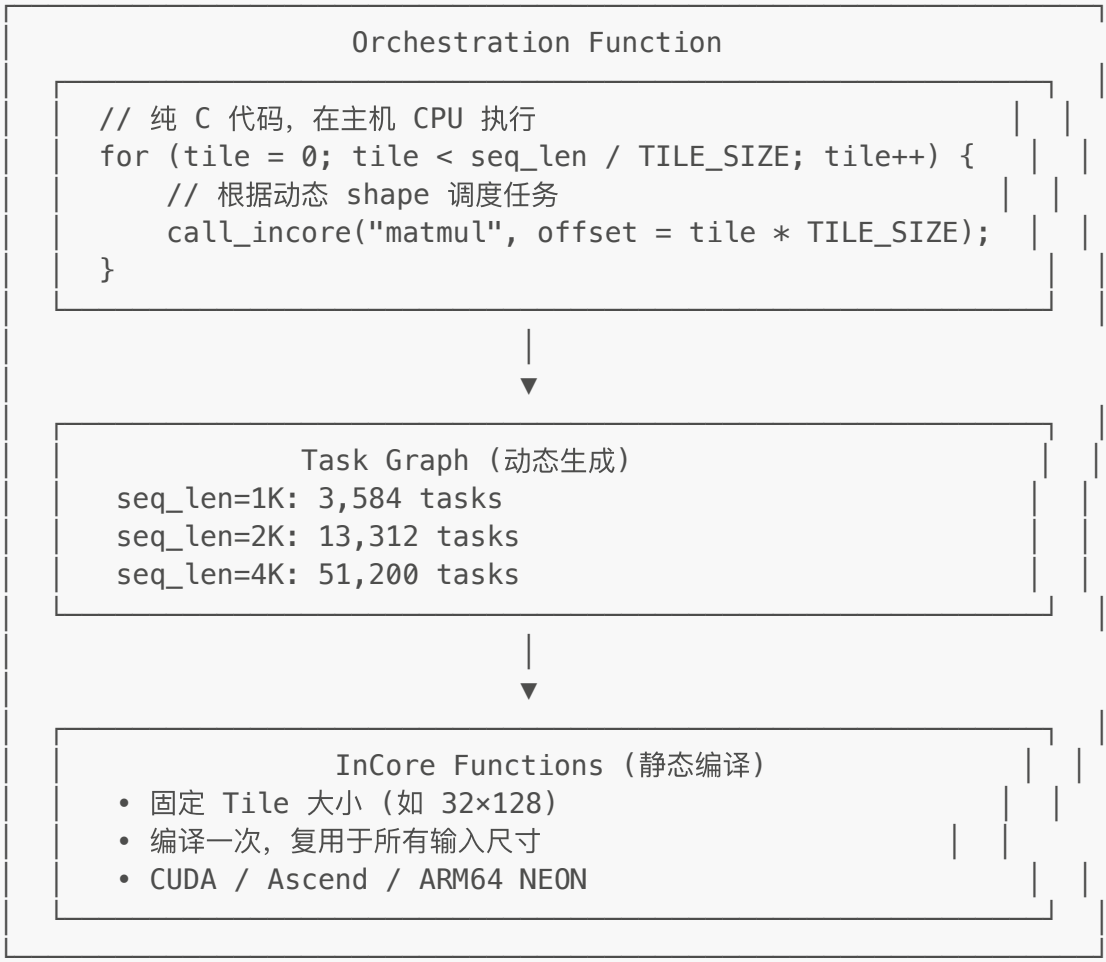

6.3 性能分析

关键问题： Orchestration Function 是否会成为性能瓶颈？

根据 LLaMA 7B 的测试数据：

Sequence Length	Task Graph 构建时间	推理时间（估计）	占比
1K	0.8 ms	~50 ms	1.6%
2K	2.6 ms	~100 ms	2.6%

Sequence Length	Task Graph 构建时间	推理时间（估计）	占比
4K	9.3 ms	~200 ms	4.7%

结论： 只要 Task Graph 构建时间远小于 InCore 函数的执行时间，Orchestration Function 就不会成为瓶颈。在实际场景中：

- **构建时间 O(N²)**: 主要来自 Flash Attention 的 N×N 交叉依赖
- **执行时间 O(N²)**: Flash Attention 本身就是 O(N²) 复杂度
- **比例稳定**: 构建时间占比基本保持在 2-5%

6.4 优势总结

特性	传统方法	PTO Orchestration
动态 shape	需要多个编译版本	✅ 原生支持
编译时间	每种 shape 都要编译	✅ InCore 只编译一次
运行时开销	无	~2-5% (可接受)
灵活性	低	✅ 任意控制流
依赖管理	手动	✅ 自动建立

快速开始

安装依赖

```
pip install -r requirements.txt
```

运行示例

```
# Fused Softmax 示例
python examples/pto_fused_softmax.py

# LLaMA 7B Layer 示例
python examples/pto_llama7B_dynamic.py

# 性能测试
cd examples && gcc -O2 -I.. -o test_llama_performance
test_llama_performance.c
./test_llama_performance
```

生成的文件结构

```
examples/
├── output_pto/           # PTO Assembly
│   └── llama7b/
│       └── llama7b_layer.pto
├── output_arm64/         # ARM64 NEON 代码
│   └── llama7b/
│       ├── tile_matmul.c
│       ├── rmsnorm_tile.c
│       └── llama_layer_dynamic_orchestration.c
├── output_cuda/          # CUDA 代码
│   └── llama7b/
│       └── *.cu
└── output_ascend910b/    # Ascend 910B 代码
    └── llama7b/
        ├── *.cpp
        ├── llama_layer_dynamic_task_graph.txt
        └── llama_layer_dynamic_task_graph.pdf
```

License

MIT License